



IDENTIFICAÇÃO DO TIPO E DA SEVERIDADE DO DESBALANCEAMENTO DE ROTORES POR MEIO DA ANÁLISE DA ASSINATURA DE CORRENTE COM APRENDIZADO DE MÁQUINA MULTICLASSES

R. N. Tominaga
IFSC

F. S. Pacheco
IFSC

C. A. Penz
IFSC

S. L. Avila
IFSC

Resumo

A saúde de uma máquina elétrica rotativa pode ser avaliada através do monitoramento de grandezas elétricas e mecânicas associadas à sua operação. Quanto mais informação estiver disponível, mais fácil pode ser diagnosticar o seu estado operacional. Para se estudar esse tema, foi construída uma bancada de teste que permite inserir desbalanceamentos propositalmente sobre o eixo de um motor de indução. No presente trabalho, fica-se restrito a diagnósticos utilizando os transitórios de corrente do motor. A partir dessa assinatura, e entendendo-se que se trata de um problema com características não-lineares e multiclasse, fez-se o uso de ferramentas computacionais para proceder a identificação (tipo) e a classificação (severidade) dos desbalanceamentos. Os algoritmos estudados aqui foram Máquina de Vetores de Suporte (SVM), Árvore de Decisão (DTC) e *one-vs-one* (OvO). Os resultados obtidos atestam a eficiência da metodologia proposta. A comparação das estratégias de aprendizado de máquina, bem como os cuidados necessários quanto ao processamento de sinais, também são contribuições deste trabalho para a engenharia de manutenção.

Palavras chave

Máquinas elétricas rotativas; Análise de sinais de corrente; Identificação de desbalanceamento; Aprendizado de máquina.

1 INTRODUÇÃO

O diagnóstico eficaz de falhas, por meio da instrumentação de monitoramento em tempo real, pode melhorar a segurança e a confiabilidade na operação de máquinas rotativas [1]. Ele também pode fornecer uma base sólida nos fundamentos da causa e efeito da falha. A maioria das técnicas existentes para monitoramento de condições e diagnóstico de falhas é baseada em medições de corrente [2], vibração [3], campo eletromagnético externo [4] e/ou temperatura [5].

A análise de assinatura de corrente do motor (MCSA) tem sido usada para monitoramento de condições em aplicações industriais [2]. Uma vantagem do MCSA em relação a outras técnicas é a simplicidade de sua instrumentação. Não há requisitos para ajustes mecânicos complexos, como os necessários para sensores de vibração; ou mesmo atenção para a complexidade do ambiente, como a presença de campos eletromagnéticos externos. Entretanto, cabe ressaltar que a interpretação da MCSA não é evidente, devido principalmente aos ruídos inerentes ao sinal em ambiente industrial. Assim, MCSA necessita de algoritmos complementares que em geral são custosos computacionalmente e dependem da experiência de um profissional.

O principal benefício do emprego de algoritmos de aprendizado de máquina (ML) é a menor dependência da experiência no problema para se obter resultados satisfatórios. A aplicação de técnicas de ML para o diagnóstico de comportamento de máquinas rotativas se tornou alvo de muitas pesquisas nos últimos anos.

É consenso que, quanto mais informações se têm, mais fácil será o gerenciamento da integridade de um sistema. Apesar disso, diferentemente dos ambientes controlados de laboratório, em plantas industriais pode ser difícil realizar a instalação de sensores em local e/ou em condições adequadas.

Nesse contexto, realizou-se este estudo. Para uma questão industrial relevante e bastante comum, o processo de desalinhamento do rotor de um motor elétrico, e com uma instrumentação de baixo custo, simples e fácil de instalar (MCSA), desenvolveu-se uma metodologia que usa ML para identificar o tipo e a severidade de falhas de desbalanceamento.

A classificação multiclasse significa identificar três ou mais tipos de ocorrências. De acordo com a ISO 1940-1 [6], existem quatro tipos de falhas de desbalanceamento com três níveis de gravidade cada.

Qualquer máquina deve ser parada para manutenção. Quando o equipamento retorna ao estado natural de operação, o transitório da corrente indicará a condição saudável da máquina. Consequentemente, recomenda-se um procedimento de ML dito supervisionado: a comparação direta entre dados ditos saudáveis e dados ainda não classificados. Entre as técnicas mais relevantes, destaca-se máquina de vetores de suporte (SVM), árvore de decisão (DTC) e *one-vs-one* (OvO). Elas se destacam, pois resolvem com eficiência uma classificação multiclasse e não linear. Não linear devido à disparidade da operação das condições do motor, por exemplo, variações de carga e fonte de alimentação.

Este artigo apresenta a metodologia de diagnóstico desenvolvida e realiza um comparativo entre as três técnicas de ML citadas.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 Desbalanceamentos em rotores

Define-se desbalanceamento do motor como o desequilíbrio de massa existente com relação ao eixo de rotação do motor. Alternativamente, o desbalanceamento é a distância existente entre o centro de massa com o eixo de rotação do motor. Assimetrias, tolerâncias dos desvios de forma e imperfeições da montagem são responsáveis pela existência do desbalanceamento em motores [6][7].

Existem quatro tipos de desbalanceamento quando é levada em consideração a posição relativa entre os eixos de rotação e de massa [8]: estático, quase estático, acoplado e dinâmico. A Figura 1 representa esses tipos de desbalanceamentos.




Figura 1: Tipos de desbalanceamento em rotores

O desbalanceamento estático ocorre quando o eixo de massa está deslocado paralelamente ao eixo de rotação. Esta denominação se deve ao fato de que quando a máquina é desligada, o eixo tende a girar até que o ponto de maior massa esteja para baixo, tornando-o facilmente detectável. Este desbalanceamento pode ser facilmente corrigido com a adição de uma massa de balanceamento diametralmente oposta ao centro de gravidade em um plano perpendicular ao eixo de rotação.

No desbalanceamento acoplado o eixo de massa intercepta o eixo de rotação no centro de gravidade do rotor. Este desbalanceamento é equivalente a duas massas em dois planos diferentes, deslocadas de 180° entre si. A amplitude desse desbalanceamento é determinada pelas massas responsáveis pelo desbalanceamento, pelo raio existente entre o eixo de rotação

e as massas e pela distância entre elas. Este desbalanceamento pode ser corrigido com a adição de duas massas de balanceamento também em planos opostos e deslocadas de 180° entre si, de tal forma que as massas fiquem diametralmente opostas.

O desbalanceamento dinâmico ocorre quando o eixo de massa não é paralelo ao eixo de rotação e nem o intercepta. Este é o desbalanceamento mais comum, e pode ser corrigido com a adição de pelo menos duas massas em planos perpendiculares ao eixo de rotação. Em um rotor real, é comum que ocorra uma série de pequenos desbalanceamentos que podem ser definidos por um desbalanceamento dinâmico equivalente. Este desbalanceamento pode ser representado pela combinação de um desbalanceamento estático e um acoplado.

No desbalanceamento quase estático, o eixo de massa intercepta o eixo de rotação em um ponto diferente do centro de gravidade. Este desbalanceamento pode ser considerado um caso especial do desbalanceamento dinâmico.

2.2 Ferramentas de aprendizado de máquina

O aprendizado de máquina consiste no desenvolvimento de um algoritmo capaz de executar uma tarefa sem a utilização de instruções explícitas. Esses algoritmos executam as tarefas com bases em padrões e inferências de um conjunto de dados. Aqui serão utilizados as estratégias de aprendizado OvO, DTC e SVM.

O OvO é um algoritmo que classifica através de agrupamento de pares de classe. Usualmente, o OvO é utilizado para comparar apenas duas classes. Contudo, é possível fazer um agrupamento deste método permitindo a sua transformação em um classificador multiclasse. No momento da predição, a classe que receber mais votos é escolhida para classificar a amostra. Devido a esse agrupamento, o OvO é computacionalmente mais custoso que os demais [9].

O DTC é um algoritmo que busca uma generalização de regras para a classificação das amostras. Essas regras visam descrever as características mais marcantes de um conjunto até chegar a uma classificação. DTC é hábil tanto para problemas binários quanto para problemas multiclasse [10].

O SVM é um algoritmo que visa distinguir classes através da modelagem de um hiperplano que melhor separa essas classes. O hiperplano é gerado através da maximização das distâncias mínimas geradas para cada uma das classes a partir do mesmo. Existe uma variação desse algoritmo que é válido para problemas multiclasse, que a máquina de vetores de suporte multiclasse (MSVM) [11].

3 BANCADA DE DESBALANCEAMENTO

A bancada de desbalanceamento pode ser dividida em duas partes: a primeira relativa ao aspecto eletromecânico da bancada; e a segunda referente à instrumentação que é utilizada para a aquisição de dados.

3.1 Aspecto eletromecânico

A bancada de desbalanceamento consiste em uma estrutura metálica sobre cavalete metálico com *vibrastop*. A estrutura metálica facilita no aterramento da instrumentação. O *vibrastop* ajuda no amortecimento de certos ruídos que são indesejados na aquisição de dados.

Sobre a estrutura metálica foi instalado um motor de indução trifásico WEG 220/380 V; 60 Hz; 4 polos; 0,75 HP. O motor escolhido é de pequeno porte para emular as principais aplicações industriais.

Para o acionamento do motor é utilizado um inversor da fabricante WEG CFW500. Este inversor possui faixas de tensão de 0 a 600 V, corrente máxima de 200 A e frequência de 0 a 500 Hz. A utilização do inversor para a bancada foi necessária devido à necessidade de flexibilidade em alterar a rotação do motor conforme a necessidade.

Ao eixo do motor é acoplado a uma peça metálica simétrica e sem desequilíbrio de massa. Esta peça possui três discos de inércia com 24 furos igualmente espaçados para permitir a inserção

de desbalanceamentos propositalis. O acoplamento foi projetado para minimizar o desalinhamento do sistema. Esta peça é apoiada por dois mancais de rolamentos idênticos com base rígida.

A Figura 2 apresenta a bancada. Além dos componentes mencionados anteriormente, a foto permite apresentar o como é feito a inserção dos desbalanceamentos (A). Também, são apresentados o sensor óptico (B), os acelerômetros (C) e os sensores indutivos (D). Entretanto, no presente trabalho apenas o sensor óptico é utilizado para determinar a fase. Os detalhes do senso óptico e da instrumentação utilizada para adquirir os sinais de corrente são mostrados na próxima seção.




Figura 2: Estrutura metálica da bancada de desbalanceamento

3.2 Instrumentação

Para a escolha do dispositivo de aquisição de dados, foi considerado a afinidade para trabalhar com o mesmo e o seu poder de processamento. Neste contexto, o escolhido foi a placa USB 6212 da *National Instruments*. O equipamento possui 16 entradas analógicas com 4 faixas de entrada programáveis ($\pm 0,2$ V a ± 10 V) com resolução de 16 bits, taxa de amostragem de 400 kS/s, 2 saídas analógicas, 32 linhas de E/S digital. A entrada USB do dispositivo é utilizada tanto para alimentação do módulo quanto para transferir os dados para o computador.

Para aumentar a resolução da leitura foi optado pela utilização de entradas diferenciais, ou seja, duas entradas analógicas são utilizadas para a leitura de uma grandeza. Devido a este fato, foi necessária a utilização de dois dispositivos de aquisição. Foi definido que um desses dispositivos estaria destinado a coletar grandezas de natureza mecânica, provenientes de sensores indutivos, acelerômetros e sensor óptico e o outro destinado para coletar grandezas de natureza elétrica, provenientes dos transdutores de corrente.

O modelo dos sensores indutivos utilizados é BAW M12MG2-ICC20B-BP00,2-GS04. Possui uma alimentação de 24 Vcc e é capaz de representar a faixa de 0,5 a 2 mm em um sinal de corrente de 4 a 20 mA. Para cada mancal, existem dois sensores indutivos perpendiculares entre si. Para que o sinal possa ser interpretado pelo dispositivo de aquisição de dados, para cada sensor indutivo é utilizado um resistor de 240 Ω .

Os acelerômetros utilizados são do modelo 601A02, pertencente ao fabricante IMI Sensors. Este modelo possui uma sensibilidade de 10,2 mV/(m/s²), faixa de medição de ± 490 m/s² e resposta em frequência de 0,27 a 10.000 Hz. Os mesmos ficam acoplados aos mancais existentes na bancada. Para que o sinal possa ser interpretado pelo dispositivo de aquisição de dados, para cada acelerômetro foi utilizado um condicionador de sinal. O modelo do condicionador é MACXMCR-UI-UI-UP, pertencente ao fabricante Phoenix Contact.

O sensor óptico utilizado é do modelo BOS 18KF-PA-1LQP-S4-C, pertencente ao fabricante Balluff. Pode ser alimentado de 10 a 30 V em corrente contínua e o mesmo possui um contato normalmente aberto e outro fechado. Este foi instalado próximo ao eixo metálico que possui os discos de inércia. Para que o sinal possa ser interpretado pelo dispositivo de aquisição de dados, é utilizado um divisor de tensão composto por dois resistores de 10 k Ω .

O modelo do transdutor de corrente utilizado é LA 25-NP, pertencente ao fabricante LEM. É um transdutor de efeito Hall e possui isolamento galvânica. Este transdutor necessita de uma alimentação simétrica de 15 Vcc. O mesmo foi inserido em uma placa eletrônica de fabricação caseira de tal forma que o transdutor interprete o sinal de corrente de até 5 A e converta para um sinal de 25 mA. O sinal é convertido em tensão através de um resistor também inserido na placa.

A placa eletrônica, ainda, possui dois relés que permitem a isolamento do transdutor de corrente. Os relés são comandados por um circuito integrado ULN2803, que possui um conjunto de transistores Darlington, e o mesmo recebe um sinal da saída digital do dispositivo de aquisição de dados. Na bancada são utilizados três transdutores de corrente a fim de mensurar a corrente que percorre os três enrolamentos do motor de indução.

4 AQUISIÇÃO DE DADOS

Foi construído um banco de dados com a condição saudável da máquina e quando a mesma é sujeita aos desbalanceamentos estático, acoplado e dinâmico. Para poder fazer um teste de versatilidade entre os algoritmos de aprendizado de máquina, o banco de dados foi construído para três velocidades distintas e três níveis de severidade para os desbalanceamentos.

As três classes de velocidade do rotor foram obtidas com base na variação da frequência de alimentação do motor. O inversor de frequência permite fazer tal variação. Foram utilizadas as velocidades para frequência de 5 Hz, 7,5 Hz e 10 Hz.

Os três níveis de severidade de desbalanceamento foram definidos com base na variação da massa que é inserido no disco de inércia. Foram definidos os níveis 1, 2 e 3, na qual quanto maior o índice, maior é o peso da massa que causa o desbalanceamento. As massas foram inseridas no disco de inércia através de um parafuso e foram utilizadas algumas porcas para poder aumentar a massa nos pontos desejados. Vale ressaltar ainda que foi certificado de que os parafusos estivessem bem apertados ao furo para garantir que não houvesse vibração. Essa vibração poderia prejudicar a qualidade do banco de dados.

Para a construção do banco de dados foi necessária a utilização do software Labview [12]. Para cada amostra foi utilizado uma frequência de amostragem de 50.000 amostras por segundos e foram registrados no total de 200.000 pontos por amostra. Isto resulta em uma janela de 4 segundos. Estes valores foram escolhidos para que os resultados obtidos possam ser comparados a outros trabalhos que já foram realizados na mesma bancada.

Foi levada em consideração a preocupação de efetuar todos os ensaios no menor período possível para evitar interferências externas que possam estar poluindo o banco de dados. Também foi levada em consideração a preocupação de garantir que o sistema entre em regime antes de aferir as grandezas para evitar alterações no banco de dados.

5 PROCESSAMENTO DE DADOS

Após a criação do banco de dados, foi pensado em como as informações contidas deveriam ser modeladas para que pudesse usar os algoritmos de aprendizado de máquina apresentados. Para isso, foi utilizado o software Matlab [13]. A decisão para a utilização deste software foi dada pela familiaridade e facilidade para a manipulação das informações que o mesmo fornece.

A utilização de muitos processos para formatar o banco de dados podem inutilizar informações ou características do banco de dados. Isso não é interessante para um algoritmo de aprendizado de máquina, pois o mesmo teria maiores dificuldades para inferir um diagnóstico com exatidão.

Todavia, um sistema preditivo é considerado eficaz quando o mesmo consegue captar apenas as características mais relevantes do banco de dados para inferir um resultado. Qualquer característica que não tem relevância pode viciar um sistema preditivo a gerar padrões incongruentes. Esses padrões podem diminuir a eficácia do algoritmo.

Sendo assim, utilizar o banco de dados exatamente da forma como foi adquirido da bancada não é uma boa opção. O sinal no domínio do tempo possui 200.000 pontos por amostra. Utilizar todos estes pontos é inviável para um algoritmo de aprendizado uma vez que isso iria requerer muito processamento computacional.

Também, para cada amostra, existe uma defasagem angular específica. Essa defasagem iria dificultar muito o algoritmo de aprendizado, pois o mesmo iria tentar buscar algum padrão através da existência dessa defasagem para gerar o diagnóstico. O problema é que não existe nenhuma relação com o tipo de desbalanceamento com essa característica.

Para solucionar esse problema, foi optada a utilização da transformada rápida de Fourier (FFT). Sendo assim, o sinal no domínio do tempo é transformado para o domínio da frequência. Isso resolve o problema relacionado com a defasagem angular do sinal. Todavia, ainda existem muitas componentes para representar a amostra. Sendo mais específico, existem 25.000 componentes por amostra, conforme o teorema de Nyquist.

Para facilitar o treinamento do algoritmo, foi utilizado um critério visual que consiste selecionar as componentes que possuem variações na amplitude de acordo com o tipo de desbalanceamento. Para uma frequência fundamental f_1 , sendo esse valor podendo ser 5 Hz, 7,5 Hz e 10 Hz, foi selecionado as frequências $0,5*f_1$, $1,0*f_1$, $1,5*f_1$, $3,0*f_1$, $5,0*f_1$ e $7,0*f_1$. As demais componentes foram dispensadas ou porque possuem uma amplitude muito pequena, o que torna mais susceptível a ruídos e, portanto, menor a confiabilidade, ou porque não trazia informações novas para os múltiplos de frequência selecionados.

Para confirmar que os múltiplos de frequências selecionados realmente possuem a capacidade de poder distinguir o banco de dados entre as possíveis classificações de desbalanceamento, foi desenvolvido histogramas para averiguar variações nas amplitudes de acordo com o tipo de desbalanceamento.

A Figura 3 mostra parte dos histogramas construídos para a análise de dados. Foi adotado um critério de cores que facilita a visualização do tipo de desbalanceamento conforme mostra a legenda localizada no canto direito.

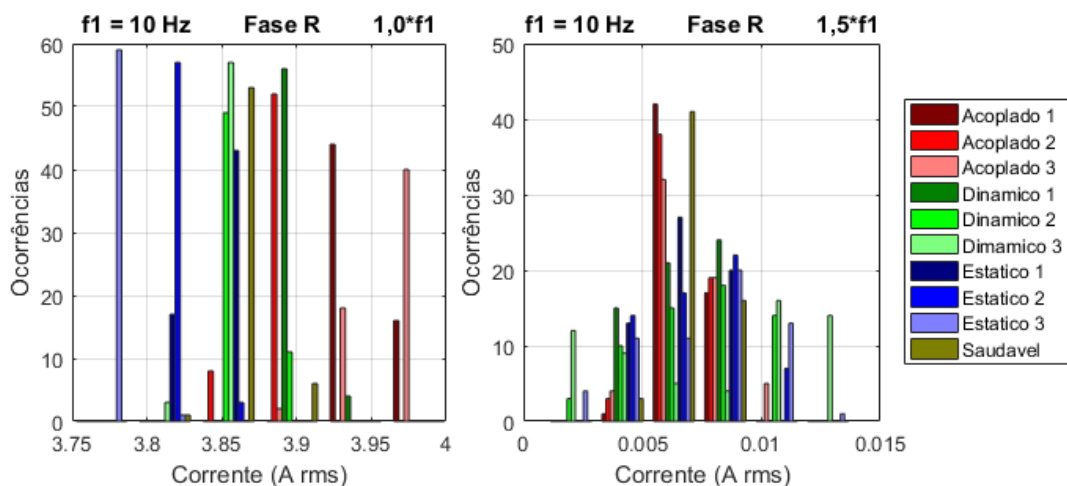


Figura 3: Histograma da corrente para diferentes casos de desbalanceamento

É possível visualizar que no desbalanceamento estático existe uma redução na amplitude da componente fundamental do sinal quando comparado com a condição saudável da máquina. Esta redução é proporcional à intensidade do desbalanceamento.

No desbalanceamento acoplado é possível visualizar que existe um aumento na amplitude da componente fundamental do sinal quando comparado com a condição saudável da máquina. Este aumento é proporcional à intensidade do desbalanceamento.

Para o desbalanceamento dinâmico é difícil fazer uma distinção em relação com a condição saudável da máquina, pois a amplitude da fundamental em ambos os casos é parecida. Todavia, quando é feita uma análise visual na componente que é 1,5 vezes a componente fundamental, o cenário muda. É possível visualizar que existe uma oscilação na amplitude nessa componente no caso do desbalanceamento dinâmico enquanto que, na condição saudável, não é possível visualizar essa oscilação.

Vale ressaltar ainda que a componente que é 1,5 vezes a componente fundamental possui certa dificuldade para distinguir o desbalanceamento estático e ainda possui ainda mais dificuldade para distinguir o desbalanceamento acoplado.

Os outros múltiplos de frequência que não foram mostrados também possuem certa contribuição para a distinção dos tipos de desbalanceamento e também é possível fazer uma análise visual semelhante ao o que foi mostrado para os múltiplos $1,0 \cdot f_1$ e $1,5 \cdot f_1$.

Outra conclusão que foi obtida na inspeção visual é o fato de que é mais fácil reconhecer o tipo de desbalanceamento quando o mesmo ocorrer em maior intensidade e frequência.

Para fazer as análises de aprendizado de máquina, usou-se o *Colaboratory*, uma plataforma do Google. Este software permite trabalhar com a linguagem Python e, dentre dos módulos que existem, possui um que é voltado especificamente para o aprendizado de máquina. Este módulo se chama *Scikit learn* [14].

Também foram utilizados outros módulos para as análises dos dados São eles: *Numpy* [15], para a realização de operações matriciais; *Scipy* [16], para importar o banco de dados; e o *Pandas* [17], para melhorar a visualização dos resultados.

Foi tomado como critério destinar 5/6 do banco de dados para o treinamento dos algoritmos de aprendizado e o restante para avaliar a eficácia do treinamento. Foi assegurado que a mesma divisão fosse adotada para todos os algoritmos, de forma a permitir uma comparação direta entre eles.

Para cada um dos algoritmos de aprendizado de máquina, foram feitas as seguintes análises: predição para determinar tipo e severidade do desbalanceamento; predição para determinar apenas tipo de desbalanceamento; e predição para determinar apenas severidade de desbalanceamento.

As análises têm como objetivo testar a eficácia de cada um dos algoritmos em cada uma das situações propostas e concluir se é mais interessante fazer uma análise simultânea de tipo e severidade ou se é mais interessante fazer as outras duas análises em cascata.

Após estas análises, foi plotada uma matriz de confusão para facilitar a visualização de erros cometidos pelos algoritmos [X]. Esta matriz confronta os diagnósticos reais dos dados de teste com os diagnósticos gerados pelo algoritmo. Os elementos pertencentes à diagonal principal desta matriz informam os casos em que o algoritmo realizou uma predição correta. Os demais elementos mostram casos em que o algoritmo se equivocou na predição. A ideia desta providência é facilitar a visualização dos valores que são relevantes para o estudo.

O Quadro 1 mostra a matriz de confusão referente ao algoritmo de SVM, aplicada sobre o sinal de corrente da fase R e quando o motor operava com uma frequência de alimentação de 5,0 Hz. Considerando a mesma semente para a separação do banco de dados em treino e teste utilizada para definir o Quadro 1, quando é feita uma análise de tipo e severidade de desbalanceamento simultânea, o percentual de acerto é de apenas 56%. Quando é feita uma análise de tipo de desbalanceamento apenas, o percentual de acerto é de 56% também. Quando é feita uma análise de severidade de desbalanceamento apenas, o percentual de acerto é de 50%.

O Quadro 2 mostra outra matriz de confusão gerada através do algoritmo de OvO, aplicada sobre o sinal de corrente da fase S e quando o motor operava com uma frequência de alimentação de 7,5 Hz. Considerando a mesma semente para a separação do banco de dados em treino e teste utilizada para definir o Quadro 2, quando é feita uma análise de tipo e severidade de desbalanceamento simultânea, o percentual de acerto é de 74%. Quando é feita uma análise de tipo de desbalanceamento apenas, o percentual de acerto é de 77%. Quando é feita uma análise de severidade de desbalanceamento apenas, o percentual de acerto é de 51%.

O Quadro 3 mostra mais uma matriz de confusão proveniente do algoritmo de DTC, aplicada sobre o sinal de corrente da fase T e quando o motor operava com uma frequência de alimentação de 10,0 Hz. Considerando a mesma semente para a separação do banco de dados em treino e teste utilizada para definir o Quadro 3, quando é feita uma análise de tipo e severidade de desbalanceamento simultânea, o percentual de acerto é de 80%. Quando é feita uma análise de tipo de desbalanceamento apenas, o percentual de acerto é de 88%. Quando é feita uma análise de severidade de desbalanceamento apenas, o percentual de acerto é de 83%.

Diagnóstico verdadeiro	Matriz de confusão de tipo e severidade – SVM											Apenas tipo				
		A1	A2	A3	D1	D2	D3	E1	E2	E3	Sa		Ac	Di	Es	Sa
	A1	2		3							5	Ac	17	12		
	A2		6			2						Di	7	15	9	
	A3	4		6							1	Es		8	24	
	D1	2		5	1						2	Sa	8			0
	D2		2			4	3	5				Apenas severidade				
	D3						7						N1	N2	N3	Sa
	E1		1			1	1	7				N1	18	10		2
	E2								8	2		N2		29	3	
	E3									12		N3	9	19	2	
	Sa	2		3							3	Sa	7			1
Diagnóstico predito																

Quadro 1: Matriz de confusão do SVM na fase R com frequência fundamental de 5,0 Hz

Diagnóstico verdadeiro	Matriz de confusão de tipo e severidade – OvO											Apenas tipo				
		A1	A2	A3	D1	D2	D3	E1	E2	E3	Sa		Ac	Di	Es	Sa
	A1	9		1								Ac	25	3		1
	A2		8									Di	5	20	2	4
	A3			5	5						1	Es		3	29	
	D1	1	1	3	2						3	Sa	2	3		3
	D2					10		4				Apenas severidade				
	D3						7						N1	N2	N3	Sa
	E1		1					8			1	N1	20	2	8	
	E2								10			N2		14	18	
	E3									12		N3	10	3	17	
	Sa			3	2						3	Sa	5		3	0
Diagnóstico predito																

Quadro 2: Matriz de confusão do OvO na fase S com frequência fundamental de 7,5 Hz

Diagnóstico verdadeiro	Matriz de confusão de tipo e severidade - DTC											Apenas tipo				
		A1	A2	A3	D1	D2	D3	E1	E2	E3	Sa		Ac	Di	Es	Sa
	A1	10										Ac	28			1
	A2		7								1	Di	7	22	2	
	A3	3		6	2							Es		1	31	
	D1		2		8							Sa	1			7
	D2		2			8		2			2	Apenas severidade				
	D3		1			1	5						N1	N2	N3	Sa
	E1						1	8	1			N1	25	2	2	1
	E2						1		9			N2	2	28	1	1
	E3									12		N3	5	2	23	
	Sa					1					7	Sa		1		7
Diagnóstico predito																

Quadro 3: Matriz de confusão da DTC na fase T com frequência fundamental de 10,0 Hz

6 DISCUSSÃO DOS RESULTADOS E CONCLUSÃO

Independente do algoritmo de aprendizado que é utilizado, os melhores resultados são encontrados nas situações em que o motor opera com maior frequência de alimentação. Com maior velocidade, mais vibração, mais fácil o diagnóstico de desbalanceamento.

No algoritmo da DTC, aplicada na fase R e buscando uma predição de nível e severidade simultânea, o percentual de acertos nas frequências fundamentais 5,0, 7,5 e 10,0 Hz são, respectivamente, 54%, 78% e 82%.

Para os algoritmos de SVM e OvO, o kernel que resultou em melhores resultados foi o polinomial. Todavia, o grau de polinômio a ser utilizado possui grande influência tanto no percentual de acertos quanto na velocidade de processamento. No algoritmo do SVM, aplicada na fase S e buscando uma predição de nível e severidade simultânea, na frequência de 5,0 Hz, o percentual de acertos utilizando polinômio de 5º, 20º e 50º grau são, respectivamente, 30% (tempo de execução: 30 ms), 55% (30 ms) e 58% (18,5 s). Já para a frequência de 7,5 Hz, o percentual de acertos utilizando polinômio de 5º, 20º e 50º grau são, respectivamente, 30% (30 ms), 60% (30 ms) e 74% (300 ms). Por fim, para a frequência de 10,0 Hz, o percentual de acertos utilizando polinômio de 5º, 20º e 50º grau são, respectivamente, 20% (30 ms), 69% (30 ms) e 91% (125 ms). Isso permite concluir que o aumento do grau do polinômio é mais relevante quando o motor é alimentado com uma maior frequência de alimentação.

Ainda a respeito dos algoritmos de SVM e OvO, existe uma relação entre o grau de polinômio a ser utilizado com a escolha da análise a ser feita. Caso seja utilizado um polinômio de grau baixo, recomenda-se fazer a classificação de tipo e severidade de desbalanceamento separadamente, colocando as duas análises em cascata. Isso gera um percentual de acerto maior em relação à predição de tipo e severidade simultânea.

As análises mostram que existem poucas variações na predição do desbalanceamento quando é feita apenas a alternância das fases, independente da rotação do motor e do algoritmo de aprendizado de máquina a ser utilizado. Contudo, ao combinar os resultados obtidos sobre cada uma das fases, é possível fazer um algoritmo que apresenta resultados melhores.

Outra análise feita foi a remoção, individual, de um múltiplo de frequência para a realização do treinamento dos algoritmos de aprendizado. Foi detectada que a componente fundamental é a mais importante para o aprendizado, uma vez que a remoção dessa componente no treinamento, independente do algoritmo e frequência de rotação, faz com que o percentual de acerto tenha uma queda considerável.

Através de uma análise similar, também foi registrado que a componente de 1,5 vezes a componente fundamental possui certa relevância no treinamento e que a sua remoção no aprendizado piora a predição. A remoção exclusiva dessa componente, não possui tanto impacto na predição quanto a remoção da componente fundamental, todavia, se ambas as componentes forem removidas no aprendizado de máquina, fica evidente uma diminuição no percentual de acerto.

Apesar da maior importância da componente fundamental e da componente que é 1,5 vezes a fundamental, todas as outras componentes utilizadas apresentam certas informações que ajudam na predição correta do desbalanceamento. Isto é provado quando se percebe que a predição com apenas as duas componentes mais importantes é pior quando comparado na situação em que todas as componentes são utilizadas.

Entre os três métodos de aprendizado de máquina utilizados, os melhores resultados foram obtidos com o DTC. Isto se deve a dois fatos: 1) o percentual de acerto deste método é maior do que os demais; e 2) o tempo de processamento para este algoritmo é menor do que os demais. Os resultados obtidos entre os dois outros algoritmos são similares.

Os resultados obtidos atestam a validade da metodologia proposta. A comparação das estratégias de aprendizado de máquina, bem como os cuidados necessários quanto ao processamento de sinais, também são contribuições deste trabalho para a engenharia de manutenção.

Futuramente, podem ser desenvolvidos estudos que comparam os sinais de corrente com as grandezas mecânicas que também foram coletados durante a aquisição de dados. Esse estudo é interessante pois pode mostrar uma relação de equivalência ou complementaridade para a de predição de desbalanceamento em máquinas rotativas.

Bibliografia

- [1] H. Toliyat et. al, Electric machines: modelling, condition monitoring, and fault diagnosis, 2 ed., CRC Press (2017) ISBN 9781138073975.
- [2] W. T. Thomson and I. Culbert, Current signature analysis for condition monitoring of cage induction motors: industrial application and case histories. Series: IEEE Press Series on Power Engineering, 1 ed., Wiley-IEEE Press (2017) ISBN 9781119029595.
- [3] W. R. Finley et. al, Motor vibration problem: How to diagnose and correct vibration errors. IEEE Industrial Application Magazine, 21(6) (2015) 14–28. doi: 10.1109/MIAS.2014.2345811.
- [4] M. Rigoni et. al, Non-invasive monitoring system of synchronous generator using external field. Journal of Microwaves, Optoelectronics and Electromagnetic Applications 16 (2017) 70-89. doi: 10.1590/2179-10742017v16i1872.
- [5] J. Hey et. al, Online monitoring of electromagnetic losses in an electric motor indirectly through temperature measurement. IEEE Transactions on Energy Conversion, 31(4) (2016) 1347-1355. doi: 10.1109/TEC.2016.2562029.
- [6] INTERNATIONAL ORGANIZATION FOR STANDARDIZATION. ISO 1940-1: Mechanical vibration — Balance quality requirements for rotors in a constant (rigid) state —. 2 ed. Genebra: Iso, 2003.
- [7] CHAPMAN, S. J. Fundamentos de Máquinas Elétricas. 5. ed. Porto Alegre: AMGH, 2013.
- [8] O. Matsushita et al. Vibrations of rotating machinery, 1 ed., Springer (2017) ISBN 9784431554561.
- [9] M. Galar et. Al. Enhancing difficult classes in one-vs-one classifier fusion strategy using restricted equivalence functions. 17th International Conference on Information Fusion (FUSION) (2014). ISBN: 978-8-4901-2355-3.
- [10] L. Rockah, O. Maimon, Data mining with decision trees theory and applications, Machine Perception Artificial Intelligence, vol. 69, 2014.
- [11] P. Bohra and H. Palivela, Understanding and formulation of various kernel techniques for support vector machines. IEEE International Conference on Computational Intelligence and Computing Research (ICCIC) (2015). doi: 10.1109/ICCIC.2015.7435804.
- [12] National Instruments. Labview, 2020 [Online]. Disponível em: <https://www.ni.com/pt-br/shop/labview.html>
- [13] Mathworks. Matlab, 2020. [Online]. Disponível em: <https://www.mathworks.com/products/matlab.html>
- [14] Scikit-learn, 2020. [Online]. Disponível em: <https://scikit-learn.org/>
- [15] Numpy, 2020. [Online] Disponível em: <https://numpy.org/>
- [16] Scipy, 2020. [Online] Disponível em: <https://www.scipy.org/>
- [17] Pandas, 2020. [Online] Disponível em: <https://pandas.pydata.org/>