



ANÁLISE DE ORBITAIS EM MÁQUINAS ROTATIVAS PARA IDENTIFICAÇÃO DA GRAVIDADE DE DESBALANCEAMENTOS MECÂNICOS UTILIZANDO TÉCNICAS DE APRENDIZADO DE MÁQUINA.

**Leonardo
da Silva
Jablon**

IFSC

AQTech

**Bruno de
Borba**

AQTech

**Gustavo
Leão
Mourão**

AQTech

**Fabrizio Leal
Freitas**

AQTech

**Sérgio
Luciano
Ávila**

IFSC

Resumo

Manter uma ótima condição de operação e estender a vida útil de uma máquina rotativa é essencial para garantir o retorno do investimento e para garantir a lucratividade das indústrias. Neste contexto, técnicas que auxiliam na detecção de problemas, reduzindo o homem-hora de engenharia e minimizando o tempo de parada são críticos para os times de operação e manutenção.

Uma das ferramentas mais utilizadas para esse propósito é o monitoramento da condição em tempo real, especialmente o monitoramento da vibração. O monitoramento da condição ajuda a reduzir custos, aumentar a confiabilidade e a disponibilidade de componentes cruciais de máquinas rotativas. Além disso, de acordo com a norma ISO 13373-1:2012 o monitoramento da condição ainda pode auxiliar da seguinte maneira: aumentar a proteção dos equipamentos; aumentar a segurança do trabalhador; ampliar os procedimentos de manutenção; dentre outros.

Para utilizar este tipo de metodologia é necessário conhecimento profundo dos aspectos de funcionamento da máquina rotativa, além de possuir uma equipe técnica capacitada para realizar o diagnóstico assertivo sobre a condição de operação do equipamento. Neste contexto, técnicas de aprendizado de máquina (ML) estão sendo desenvolvidas. Um dos principais pontos para estas técnicas é que a análise deixa de ser subjetiva conforme experiência dos profissionais envolvidos, e torna-se baseada apenas em algoritmos computacionais. Acredita-se que a união de estratégias de ML com instrumentação industrial possui um grande potencial para melhorar o diagnóstico em máquinas rotativas.

De acordo com a literatura, desbalanceamento é um dos problemas mais comuns máquinas rotativas. Portanto, o foco dado a este projeto foi na detecção de desbalanceamento mecânico, assim como a sua severidade quando detectado.

Para alcançar este objetivo, foi desenvolvido um algoritmo de ML capaz de identificar padrões em diagramas de órbitas. As vantagens de se utilizar orbitais em comparação com outros tipos de medição de vibração é a simplicidade na instrumentação necessária além da multiplicidade de informações contidas em uma órbita. Orbital é uma técnica utilizada em análise de vibração que descreve o movimento do centro do eixo causado pela vibração excessiva quando a máquina está em operação.

Este trabalho apresenta uma metodologia de diagnóstico de falhas em geradores e motores elétricos que perfaz quatro etapas. Primeiro é medido a vibração em mancais utilizando sensores de proximidade e de aceleração em posições perpendiculares entre si, de forma a se obter um orbital. Depois, características são extraídas dos orbitais para então aplicar Principal Component Analysis (PCA) e reduzir as características extraídas para três componentes principais. Na sequência, a técnica de ML K-Nearest Neighbors (KNN) é utilizado para classificar a condição

de operação da máquina como saudável ou desbalanceada, identificando o local da falha e sua severidade. Para fins de comparação, Support Vector Machine (SVM) também é utilizado para classificação.

Os resultados práticos do método proposto são apresentados em dados simulados em uma bancada de laboratório e sua robustez é verificada analisando a taxa de acerto sobre sinais com diferentes relações sinal ruído.

Este trabalho é uma parceria entre o IFSC e a AQTech, com apoio financeiro da FAPESC 2019TR322

Palavras chave

Diagnóstico automático; Machine Learning; Desbalanceamento; Orbital

1 INTRODUÇÃO

Desbalanceamento é uma das causas mais comuns de vibração excessiva em plantas hidroelétricas. O monitoramento da vibração é uma metodologia muito comum e consolidada no mercado para detectar desbalanceamento [1]. Porém, a sua utilização requer conhecimento profundo e profissionais capacitados para diagnosticar corretamente a condição de operação da máquina. Técnicas de *Machine Learning* estão evoluindo rapidamente e suas aplicações estão trazendo melhorias no desempenho de diagnóstico de falhas [2]. Uma de suas grandes vantagens é que a análise deixa de ser subjetiva e passa a ser baseada somente em algoritmos computacionais.

Orbitais são utilizados para classificação da condição de operação das máquinas, porém este caminho ainda não é muito conhecido. A extração de características de diversos orbitais relacionados a diagnóstico de falhas foi simulado com o objetivo de detectar padrões de falhas [3] [4]. Características de orbitais como abundância e proximidade obtidas de testes foram utilizadas como entradas para um classificador do tipo *Support Vector Machine* (SVM) para detectar desbalanceamento [2]. Algoritmos de detecção de padrão em imagens baseados em algoritmos *Convolutional Neural Networks* (CNN) podem ser aplicados em orbitais gerados em uma bancada de testes para a classificação da falha [5]. Porém, tendo acesso ao orbital é possível utilizá-lo de outras formas.

Este artigo apresenta uma nova estratégia em quatro passos. Primeiro a vibração é medida em duas mancais da máquina rotativa utilizando sensores de proximidade e de aceleração em posições perpendiculares para se obter os respectivos orbitais. Depois, características são extraídas dos orbitais. *Principal Component Analysis* (PCA) é aplicado para reduzir as características extraídas em três componentes principais. Finalmente, o algoritmo *K-Nearest Neighbors* (KNN) é utilizado para classificar a condição de operação da máquina como saudável ou desbalanceada em três diferentes níveis de severidade, além de identificar o local da falha. SVM também é utilizado para a classificação para comparação com os resultados do KNN.

No capítulo 2, uma breve introdução sobre orbitais, técnicas de machine learning e estatística é apresentado. No capítulo 3 é apresentado a bancada de testes utilizada. No capítulo 4, a metodologia utilizada neste artigo é apresentada. No capítulo 5 os resultados obtidos são apresentados assim como a discussão sobre eles. Por fim, no capítulo 6 a conclusão é apresentada.

2 FERRAMENTAS MATEMÁTICAS

2.1 Orbital

Uma das técnicas mais utilizadas em análise de vibração, o orbital descreve o movimento do centro do eixo causado pela vibração quando ele está em rotação [1]. Pode ser obtido posicionando dois sensores deslocados de 90° entre si. Muitas características podem ser extraídas de um orbital, tais como características geométricas, características de momento e características angulares. Neste estudo, foram utilizadas características geométricas para a

classificação: área, desvio padrão, valor médio do raio, valor mediano do raio e valor pico a pico do raio.

2.2 Desbalanceamento

Desbalanceamento presente nas máquinas pode ser expressado em termos de uma massa equivalente m com uma excentricidade e e geralmente é dado pelo produto me . Quando temos uma máquina em rotação, a massa de desbalanceamento m rotaciona com a mesma velocidade angular do eixo. Neste sentido, a força que descreve o movimento oscilatório pode ser escrita da seguinte maneira:

$$F_{eq} = me * \omega^2 \sin(\omega t - \theta), \quad (1)$$

onde F_{eq} é a força de desbalanceamento resultante agindo no sistema, m é a massa de desbalanceamento, e é o raio de rotação e ω é a velocidade angular. Desta equação, podemos notar que a força de desbalanceamento é diretamente proporcional a massa de desbalanceamento e é quadraticamente proporcional ao aumento da velocidade.

Finalmente serão apresentados alguns benefícios advindos de um bom domínio do valor da X_q , entre eles a possibilidade de se observar, em tempo real, o ângulo de carga do gerador, juntamente com suas vantagens no sistema de proteção do gerador.

2.3 Principal Component Analysis

Principal Component Analysis é um procedimento estatístico que utiliza de transformação ortogonal para converter um conjunto de observações de variáveis possivelmente correlacionados em um conjunto de valores de variáveis linearmente não correlacionadas [2]. A transformação segue o princípio em que a primeira componente principal possui a maior variância possível e cada componente sucessor possui a maior variância possível e é ortogonal ao anterior. Neste sentido, a redução das dimensões das características extraídas dos orbitais é feita aplicando-se PCA de uma forma que as variáveis resultantes não representam variáveis produzidas pelo sistema.

2.4 Support Vector Machine

Support Vector Machine é um modelo de aprendizado supervisionado. Ele obtém uma fronteira linear no espaço das entradas do algoritmo [7] considerando padrões e relações entre as entradas. Essa fronteira é então utilizada para criar a regra de tomada de decisão para classificação.

2.5 K-Nearest Neighbor

K-Nearest Neighbor é um algoritmo onde 'K' denota o número de vizinhos próximos que são utilizados para prever a classe de uma amostra. Para classificar uma amostra x , KNN seleciona k amostras mais próximas da amostra x no conjunto de amostras de treino e utiliza k instâncias para determinar a classe da instância x [8].

2.6 Coeficiente de Correlação de Pearson

Coeficiente de Correlação de Pearson (PCC) é uma medida estatística de correlação linear entre duas variáveis. Em geral, $|PCC| > 0$ indica correlação entre duas variáveis onde $|PCC| \in [0, 1]$ [9]. Portanto, quanto maior o PCC, o melhor será o resultado tentando explicar o comportamento de uma variável utilizando outra. Ele pode ser calculado através da seguinte equação:


$$pcc(x, y) = cov(x, y) / (\sigma(x) * \sigma(y)), \quad (2)$$

onde cov é a covariância entre x e y e σ é o desvio padrão.

3 BANCADA DE TESTE

A bancada de testes é constituída de uma estrutura de base metálica sob uma armação metálica, como pode ser visto na Figura 1. As principais características da bancada são: acoplamento construído de forma que não causa desalinhamento ao sistema (A); mancais com base rígida para minimizar desalinhamento; três discos de inércia, permitindo desbalanceamento estático e dinâmico com passos de 15° para introdução de massas; diâmetro largo para sensores de deslocamento; suporte para o sensor de fase (B); suporte para os acelerômetros (C); suporte para os sensores de deslocamento (D). A massa do eixo é aproximadamente 38,78 kg.

Figura 1 – Bancada de teste.



As principais características do sensoriamento são a sensibilidade e a resposta em frequência. Portanto, é conveniente: acelerômetros com alta sensibilidade (100 mV/g ou maior); proximetros com faixas de medição próxima à folga dos mancais (ex: 0.5-2mm); e frequência de resposta variando de $\frac{1}{4}$ da rotação nominal até 3 vezes a passagem das pás da turbina; entradas de 4-20mA para os proximetros e padrões IEPE/ICP para acelerômetros; frequência de amostragem (f_s) maior do que duas vezes a máxima frequência de análise; e tempo total de registro tal que $\Delta f < 0.2$ Hz (para $f_s = 1000$ Hz, 5 segundos são suficientes).

O sistema de aquisição escolhido foi o SMGer-800. O modelo utilizado oferece 12 entradas analógicas com faixas de entrada programáveis (± 10 V e ± 20 mA), 24 bits de resolução, taxa de amostragem de 20kS/s.

4 METODOLOGIA

Os passos para se obter as características e identificação de desbalanceamento podem ser resumidos no fluxograma ilustrado na Figura 2.

Primeiro, a vibração nos dois mancais é medida utilizando sensores de deslocamento e de aceleração em posições perpendiculares entre si. Em seguida, é aplicada transformação polar (θ , R) nas coordenadas retangulares (x , y) obtidas dos orbitais em cada mancal. A Figura 3 ilustra a vibração natural da bancada. Depois, cinco características são extraídas dos dados coletados: área, desvio padrão, pico a pico, mediana e média. PCA é aplicado para reduzir essas características em três componentes principais. Finalmente, o algoritmo KNN é utilizado para classificar a condição de operação da máquina como saudável ou desbalanceada em três diferentes níveis de severidade além de identificar o local da falha. SVM também é utilizado para fins de comparação. A robustez do algoritmo é avaliada calculando-se a acurácia do diagnóstico utilizando entradas com diferentes relações sinal ruído.

Figura 2 – Fluxograma.

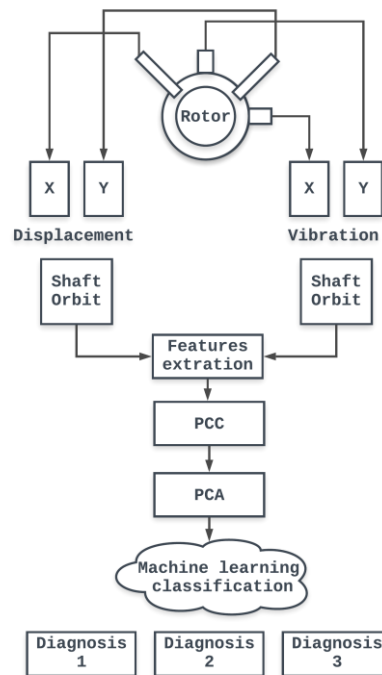



Figura 3 – Orbital.

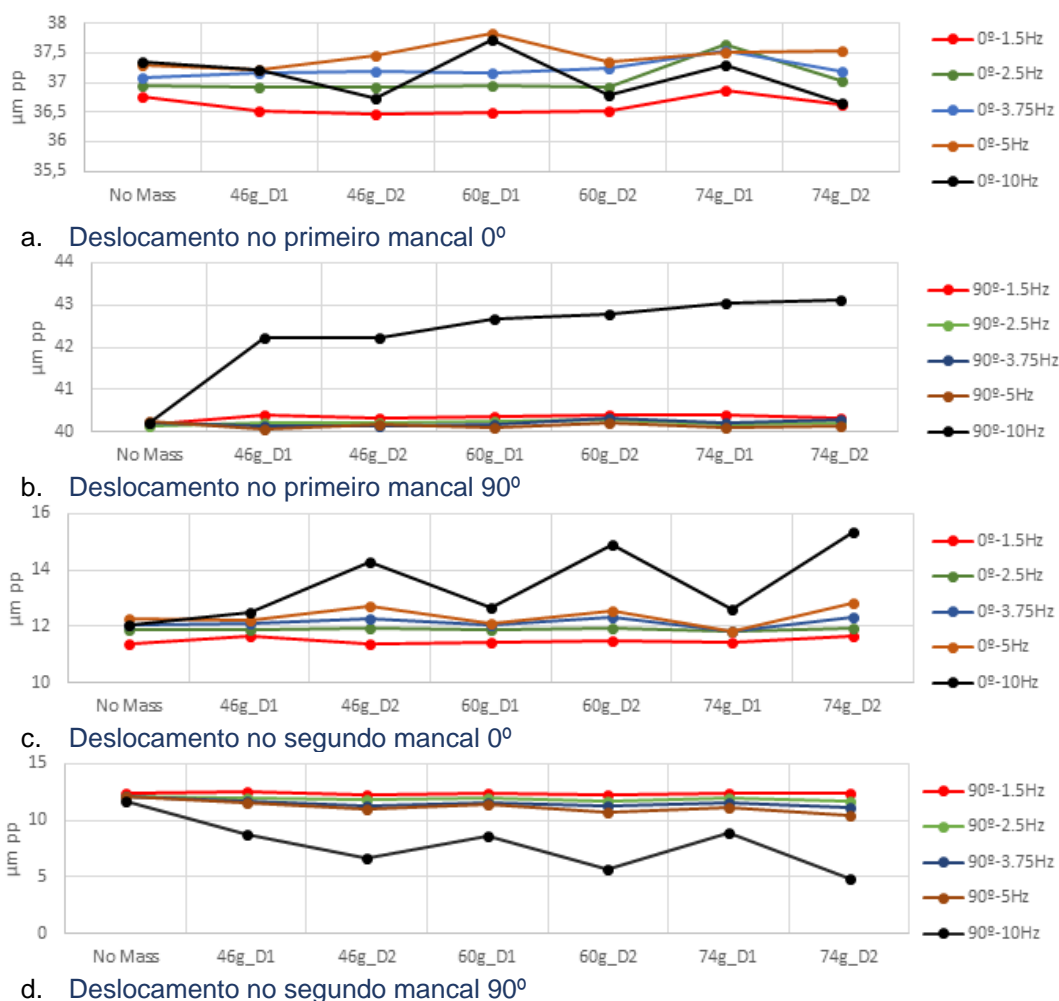


Foram conduzidos experimentos em quatro diferentes níveis de carregamento na bancada: condição normal de operação, condição de falha pequena, média e grave que correspondem a adição de massa de desbalanceamento de 0g, 46g, 60g, 74g respectivamente. As massas adicionais correspondem a 0,119%, 0,115% e 0,191% da massa total do eixo. Para as condições de falha, as massas adicionais foram posicionadas nos discos de inércia mais próximos de cada mancal, um de cada vez. Foram feitas medições em cada uma das condições para 5 velocidades diferentes: 1,5Hz, 2,5Hz, 3,75Hz, 5Hz, 10Hz. Os dados de vibração foram obtidos a uma taxa de amostragem de 10kHz.

5 RESULTADOS E DISCUSSÃO

Valores globais dos sensores de deslocamento em cada mancal foi calculado e apresentado em um gráfico para visualizar o comportamento da vibração em todos os testes conduzidos. É possível observar os gráficos obtidos na Figura 4. O eixo X deve ser interpretado da seguinte maneira: 46g_D1 significa 46g de massa adicional colocada no disco de inércia próximo ao mancal um, 60g_D2 significa 60g colocadas no disco de inércia próximo ao mancal dois e assim em diante. Os gráficos mostram que a bancada se comporta diferentemente quando a massa é adicionada próximo ao mancal um ou ao mancal dois. Além disso, é claro que o valor global do deslocamento muda muito pouco com a adição de massa, exceto pela velocidade em 10Hz. Este fenômeno é esperado, pois os mancais são de rolamento e temos uma folga muito pequena entre o eixo e o mancal.

Figura 4 - Comportamento da vibração.




Normalmente, sensores de deslocamento são utilizados para se obter o orbital, porém como não obtivemos uma mudança significativa em seu valor global, dados em velocidade obtidos dos acelerômetros foram utilizados (Figura 3). PCC foi calculado para analisar quais variáveis possuem a maior influência sobre a mudança de condição de operação. Os resultados estão disponíveis na Tabela 1. Como a área possui o menor coeficiente não será utilizada como entrada ao algoritmo de redução de dimensão. Para manter a representatividade máxima dos dados, três componentes principais foram utilizadas.

Tabela 1 – Coeficiente de Correlação de Pearson.

Característica	Valor
Desvio padrão	0,379
Pico a pico	0,380
Mediana	0,411
Área	0,173
Média	0,416


Para manter a representatividade máxima dos dados, três componentes principais foram utilizadas. A variância explicada por cada componente pode ser visualizada na Figura 5. Note que com três componentes é possível explicar mais de 95% da variância total dos dados.

Figura 5 – Variância explicada por cada componente principal.



As características calculadas dos experimentos feitos em velocidades mais baixas são notavelmente confusos para o classificador porque a vibração muda muito pouco para uma identificação mais clara. A classificação original das amostras pode ser visualizada na Figura 6. Amostras em roxo representam condição de operação sem falha, em azul falha pequena, em verde falha média e em amarelo falha grave. Na seção destacada na imagem (círculo vermelho) é possível ver que amostras com diferentes tipos de classificação estão muito próximas uma das outras, dificultando a diferenciação entre as condições de operação. Por outro lado, essa condição é reduzida quando são utilizadas apenas amostras com velocidade superior a 2,5Hz são utilizadas. De acordo com (1) este comportamento é esperado, pois a força de desbalanceamento aumenta proporcionalmente à velocidade.

Figura 6 – Classificação das amostras.



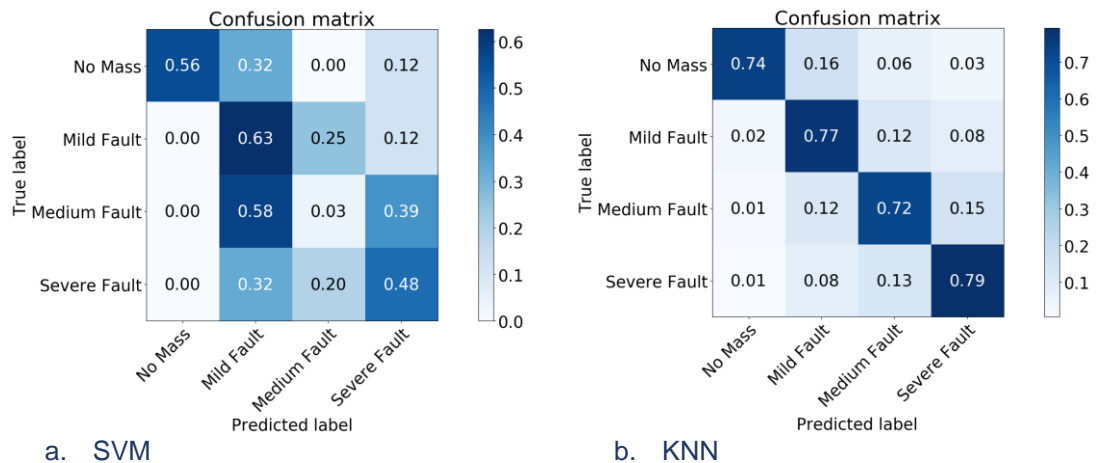
A etapa de classificação é comparada entre dois algoritmos de machine learning. As amostras de características são separadas em 50% para treino e 50% para teste. Os resultados obtidos por cada um dos classificadores são apresentados na forma de matriz confusão na Figura 7. Como podemos ver nas figuras, o algoritmo KNN obteve uma acurácia maior quando comparado com os resultados do SVM. De acordo com a breve descrição dada do SVM, este depende de uma fronteira linear para a classificação. Porém, como podemos ver na Figura 6, essas amostras não são linearmente separáveis. Isto pode explicar o fato dele ter obtido uma acurácia baixa.

Um fato interessante sobre o KNN é que: se, por exemplo, uma condição de Trip for ajustada para as condições de falha média e grave o algoritmo classificaria a condição da máquina como normal em 84% das vezes e classificaria como uma condição de Trip corretamente 90% das vezes.

Para avaliar a robustez do algoritmo foi calculado a acurácia utilizando sinais com diferentes relações sinais ruído (SNR) para cada um dos algoritmos. A acurácia pode ser calculada através da seguinte equação:


$$acurácia = \frac{TP+TN}{TP+TN+FN+FP}, \quad (3)$$

Figura 7 – Matriz de confusão para severidade da falha.



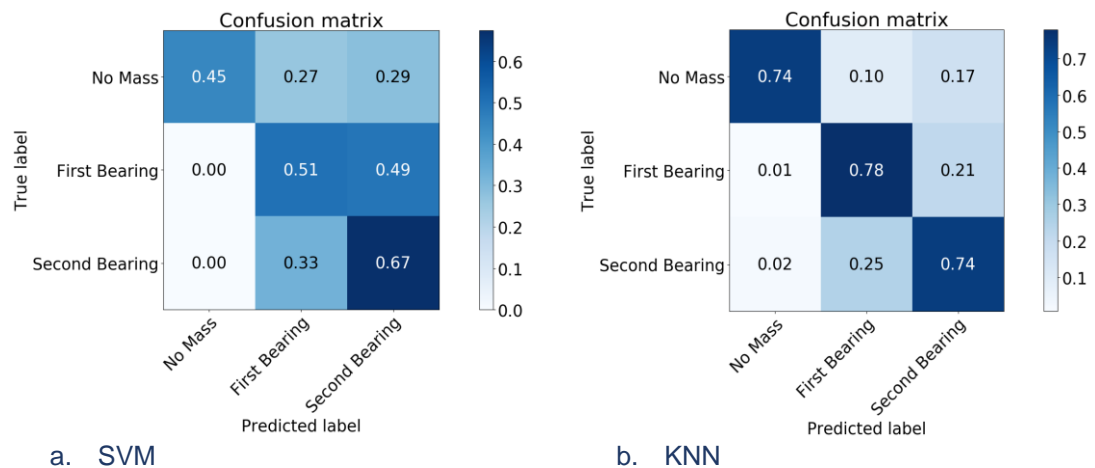
onde TP, TN, FP, FN são o número de verdadeiro positivo, verdadeiro negativo, falso positivo, falso verdadeiro respectivamente. Os resultados obtidos podem ser visualizados na Figura 8. De acordo com a figura, podemos ver que os algoritmos possuem melhor desempenho em relações sinais ruídos mais altas. Este comportamento é esperado pois relações sinais ruídos menores significam maiores ruídos inseridos nos dados de entrada. A acurácia do algoritmo se mantém maior do que 50% mesmo para condições extremas de ruídos e poderia ser utilizado neste cenário. Porém, isto não é recomendado.

Figura 8 – Acurácia com diferentes relações sinal ruído.



Em aplicações reais, a localização da massa de desbalanceamento é muito útil visto que a sua precisa localização é necessária para realizar o balanceamento da máquina. Dito isto, os algoritmos também foram utilizados para identificar a localização da massa de desbalanceamento. Os resultados podem ser visualizados na forma de matriz de confusão na Figura 9. O resultado mostra que os algoritmos podem ser muito úteis ao identificar o local da massa adicional de desbalanceamento, classificando corretamente aproximadamente 75% das vezes.

Figura 9 – Matriz de confusão para identificação do local da falha.



6 CONCLUSÃO

Este artigo apresenta uma nova estratégia em quatro passos para melhorar o desempenho do diagnóstico de desbalanceamento utilizando técnicas de machine learning em características extraídas de orbitais. O diagnóstico foi comparado entre dois classificadores. Computacionalmente mais leve, esta técnica é capaz de lidar com sinais ruidosos e de baixa amplitude em mancais de rolamento – o que é requerido para aplicações industriais.

A vibração em máquinas rotativas pode iniciar por diversos outros motivos além de desbalanceamento. Exemplos são: desalinhamento, rodopio de óleo, roçamento, falha nos elementos rolantes etc. Uma recomendação para trabalhos futuros seria de testar essa metodologia nestes outros problemas.

Bibliografia

- [1] O. Matsushita, et al., "Vibrations of rotating machinery: volume 1. Basic rotordynamics: introduction to practical vibration analysis (Mathematics for Industry)," 1st ed., Springer Japan, ISBN 9784431554554, 2017.
- [2] S. Khan and T. Yairi, "A review on the application of deep learning in system health management," *Mechanical Systems and Signal Processing*, v. 107, pp. 241-265, Jul. 2018, 10.1016/j.ymssp.2017.11.024.
- [3] Lu Yang, et al., "Analysis and comparison of axis orbit characteristics in fault pattern recognition," In *Proc. CAC*, Wuhan, Chine, 2015, pp. 859-863. 10.1109/CAC.2015.7382618
- [4] Y. Meng, L. Lu, and J. Yan, "Shaft orbit feature-based rotator early unbalance fault identification," *Procedia CIRP*, v. 56, pp. 512–515, Out. 2016. 10.1016/j.procir.2016.10.100.
- [5] H. Jeong, et al., "Deep learning-based diagnostics of orbit patterns in rotating machinery," In *PHM Society*, Denver, USA, 2016, pp. 1–7.
- [6] M. E. Elnady, J. K. Sinha, and S. O. Oyadiji, "Condition monitoring of rotating machines using on-shaft vibration measurement," In *Conf. Vib. Rotating Mach.*, IMechE London, England, pp. 820–825, Woodhead Publishing, ISBN 9780857094520, 2012.
- [7] S. F. Hussain, "A novel robust kernel for classifying high-dimensional data using Support Vector Machines," *Expert Systems with Applications*, v. 131, pp. 116-131. Apr. 2019. 10.1016/j.eswa.2019.04.037.

- [8] S. Zhang, et al., "Efficient kNN classification with different numbers of nearest neighbors," *IEEE Trans. Neural Networks Learn. Syst.*, v. 29, n. 5, pp. 1774–1785, May 2018, 10.1109/TNNLS.2017.2673241.
- [9] L. Sheugh and S. H. Alizadeh, "A note on pearson correlation coefficient as a metric of similarity in recommender system," 2015 AI & Robotics, Qazvin, 2015, pp. 1–6, 2015, 10.1109/RIOS.2015.7270736.